

实验名称: 机器学习实践: 第三次实验报告

实验日期: 2026 年 6 月 28 日

实验地点: C4-519 机房

班级: 人工智能 24-2 班

姓名: 王晨枫

学号: 2024015937

一、实验内容

任务 1: LSTM 情感分类

摘要

本实验基于 Sentiment140 英文情感分类数据集, 使用 PyTorch 搭建 LSTM 情感分类模型, 实现对文本正负情感的二分类。实验流程包括数据读取、标签归一化、文本分词、词表构建、GloVe 预训练词向量加载、Dataset/DataLoader 构造、BiLSTM + Attention 模型训练、验证集选择最优模型、测试集评估以及训练曲线保存。基础实验在全量 160 万条样本上完成 10 轮训练, 最终测试准确率达到 0.8272。随后提出三个改进版本: 第一, 通过扩大词向量维度并使用 GloVe 300d 预训练词向量增强模型表示能力, 最佳测试准确率提升至 0.8330; 第二, 引入 Early Stopping 早停机制, 根据验证集损失自动停止训练并保存最优模型, 以缓解过拟合并提高实验规范性; 第三, 加入基于 Transformer 的微调版本, 利用预训练语言模型进一步增强语义理解能力。Transformer 版本完成 10 轮训练, 最终测试准确率达到 0.9041, 用于展示模型上限与后续优化方向。

目录

摘要	1
一、实验目的	5
二、实验环境与配置	5
三、数据集与预处理	5
3.1 数据集介绍	6
3.2 数据预处理步骤	6
四、实验架构说明与基础实验流程	8
4.1 实验整体架构说明	8
4.2 基础实验流程	9
五、模型结构与参数设置	10
5.1 模型结构	10
5.2 基础实验参数	11
六、基础实验结果与分析	12
6.1 训练结果	12
6.2 结果分析	13
6.3 基础实验拟合情况与后续处理	13
七、改进版本一：扩大模型表示能力	15
7.1 改进思路	15
7.2 改进版本一结果	15

7.3 改进效果分析	18
7.4 改进版本一拟合情况与后续处理	18
八、改进版本二：加入早停机制	18
8.1 改进思路	18
8.2 早停机制的实验意义	19
8.3 早停改进总结	21
8.4 改进版本二拟合情况与后续处理	21
九、改进版本三：引入 Transformer 预训练模型	21
9.1 改进思路	21
9.2 Transformer 版本参数设置	22
9.3 Transformer 版本实验结果	23
9.4 Transformer 版本拟合状态分析	24
十、综合对比与结论	24
10.1 各实验拟合状态与解决策略汇总	26
十一、实验输出文件	26
十二、实验总结	27
附录：核心代码整理	28
附录 1 环境、路径与随机种子	28
附录 2 数据读取与标签归一化	29
附录 3 分词、词表、Dataset 与 DataLoader	30

附录 4 BiLSTM + Attention 模型结构	31
附录 5 单轮训练、验证与测试	32
附录 6 早停、最优模型保存与曲线输出	32
附录 7 Transformer 版本核心代码	34

一、实验目的

本实验的目标是使用 LSTM 网络完成英文文本情感分类任务，并通过实验结果分析模型的训练效果、泛化能力和改进方向。具体目标如下：

- 掌握文本情感分类任务的完整流程，包括数据读取、文本处理、词表构建和模型训练。
- 理解 LSTM 在序列建模中的作用，以及双向 LSTM 和 Attention 对文本分类效果的帮助。
- 记录训练集、验证集和测试集的 loss 与 accuracy，分析模型是否正常收敛。
- 在基础实验基础上，提出“扩大模型表示能力”“加入早停机制”和“引入 Transformer 预训练模型”三个改进方向。

二、实验环境与配置

实验主要在 Conda 深度学习环境中运行，并使用 CUDA GPU 进行加速。根据实验记录，环境配置如下：

项目	配置
操作系统	Windows 10
Python 环境	Conda dl
Python 版本	3.11.15
PyTorch 版本	2.7.1+cu118
GPU	NVIDIA GeForce RTX 4060 Laptop GPU
训练设备	cuda
主要依赖库	torch、pandas、matplotlib、scikit-learn、tqdm

代码中提供了自动设备检测函数：当 CUDA 可用时优先使用 cuda；若 CUDA 不可用但 Apple MPS 可用，则使用 mps；否则使用 cpu。因此，该代码可以在 Windows + NVIDIA GPU、Mac + MPS 或普通 CPU 环境下运行。

三、数据集与预处理

3.1 数据集介绍

本实验使用 Sentiment140 数据集。该数据集由英文 Twitter 文本组成，常用于情感分析任务。原始标签中，0 表示负面情感，4 表示正面情感。实验代码会将原始标签映射为二分类标签：0 表示负面，1 表示正面。

为更直观说明数据集是否均衡，可补充标签分布图。若正负样本比例接近 1:1，则说明模型训练不会明显受到类别不平衡影响。




图 1 数据集标签分布图 (Sentiment140)

图 1 分析: 该图展示 Sentiment140 数据集中正负情感样本数量均为 800,000，说明数据集整体类别分布均衡。类别均衡可以减少模型偏向某一类别的风险，使后续准确率指标更能反映模型对文本情感特征的真实学习能力。

3.2 数据预处理步骤

数据预处理是本实验的重要部分，直接影响后续模型训练质量。代码中的预处理流程如下：

- 读取处理后的 `train-processed.csv` 或原始 `training.1600000.processed.noemoticon.csv`。
- 抽取文本列和标签列，并将标签从 0/4 映射为 0/1。
- 删除空文本、空标签以及异常标签样本。
- 使用正则表达式进行英文分词，并将文本统一转为小写。
- 根据训练集统计词频，构建词表，并保留 `<pad>` 和 `<unk>` 两个特殊标记。
- 将文本转换为词编号序列，并在 `DataLoader` 中进行 padding。
- 使用 `pack_padded_sequence`，使 LSTM 忽略 padding 部分，提高训练效率。



图 2 实验数据处理流程图（数据读取 → 分词 → 词表 → DataLoader）

图 2 分析：该图概括了从原始 CSV 文本到模型输入 batch 的完整预处理链路。数据读取、标签映射、分词、词表构建、序列化、padding 和 DataLoader 构造逐层衔接，说明本实验不是直接将原始文本输入模型，而是先将文本转换为适合 LSTM 处理的定长批量序列。

四、实验架构说明与基础实验流程

4.1 实验整体架构说明

本实验可以理解为一个从“原始文本数据”到“情感分类结果”的完整流水线。整体架构由数据层、预处理层、文本表示层、序列建模层、训练评估层和结果输出层组成。各层之间逐步传递数据，最终得到模型权重、训练日志和可视化结果。

这种分层架构的好处是：数据处理、模型定义、训练评估和结果输出相互独立，便于后续替换模型结构、调整超参数或增加早停等训练策略。

层次	主要内容	作用
数据层	Sentiment140 CSV、文本列、情感标签	提供正负情感分类样本
预处理层	标签映射、文本清洗、分词、词表构建、padding	将原始文本转换为可输入模型的序列
表示层	Embedding / GloVe 预训练词向量	把离散词编号转换为连续语义向量
模型层	BiLSTM + Attention + Dropout + Linear	提取上下文语义并完成二分类
训练评估层	train/val/test、CrossEntropy、Adam、best model	训练模型并记录 loss、accuracy
结果输出层	training_history.csv、lstm_loss.png、lstm_accuracy.png、best_lstm.pt	保存报告所需的数据、图表和模型权重




图 3 实验整体架构图

图 3 分析：该图从系统层面展示了实验整体架构，包括数据层、预处理层、表示层、模型层、训练评估层和结果输出层。该结构体现了机器学习实验的工程化流程：前端数据处理与后端训练评估相互独立，便于后续替换模型、调整超参数或增加早停策略。

4.2 基础实验流程

基础实验重点验证 LSTM 情感分类模型能否在全量 Sentiment140 数据集上稳定训练，并得到合理的验证集和测试集结果。整体流程如下：

- 启动 Conda 深度学习环境，并确认 PyTorch 与 CUDA 可用。
- 读取全量 160 万条 Sentiment140 数据。
- 进行标签归一化、文本清洗、英文分词和词表构建。
- 按照 8:1:1 划分训练集、验证集和测试集。
- 构建 Dataset 和 DataLoader，并对 batch 内文本进行 padding。
- 初始化 LSTM 情感分类模型。
- 使用交叉熵损失函数和 Adam 优化器进行训练。
- 每轮分别计算 train、val、test 的 loss 和 accuracy。

- 根据验证集 loss 保存 best_lstm.pt。
- 训练结束后输出 training_history.csv、lstm_loss.png 和 lstm_accuracy.png。

五、模型结构与参数设置

5.1 模型结构

本实验模型不是最简单的单层 LSTM，而是一个 BiLSTM + Attention 情感分类模型。模型整体结构如下：



Embedding 层负责将词编号转换为连续词向量；BiLSTM 从前后两个方向建模句子语义；Attention 层为不同时间步分配权重，使模型更关注情感词；最后通过全连接层输出二分类结果。




图 4 BiLSTM + Attention 模型结构图

图 4 分析: 该图对应代码中的 LSTMClassifier 结构。文本先经过 Embedding 层转为词向量, 再通过 pack_padded_sequence 进入 BiLSTM 编码器, 随后 Attention 层对不同时间步输出分配权重, 形成上下文向量, 最后经 Dropout 和 Linear 层输出正负情感类别。该结构比单纯取最后隐藏状态更能突出情感关键词。

5.2 基础实验参数

参数	数值	说明
epochs	10	训练轮数
batch_size	256	每批样本数
embedding_dim	200	词向量维度
hidden_size	128	LSTM 隐藏层维度
num_layers	2	LSTM 层数
dropout	0.2	随机失活比例
learning_rate	0.0001	学习率
max_vocab_size	20000	最大词表规模
min_freq	2	最低词频
max_len	50	最大文本长度
seed	42	随机种子

六、基础实验结果与分析

6.1 训练结果

基础实验使用全量 160 万数据训练 10 轮，训练过程中的主要指标如下：

Epoch	train_loss	train_acc	val_loss	val_acc	test_loss	test_acc
1	0.4936	0.7616	0.4468	0.7948	0.4442	0.7974
2	0.4324	0.8034	0.4240	0.8069	0.4216	0.8090
3	0.4118	0.8138	0.4116	0.8133	0.4094	0.8151
4	0.3978	0.8207	0.4035	0.8178	0.4007	0.8188
5	0.3873	0.8260	0.3972	0.8210	0.3953	0.8208
6	0.3789	0.8302	0.3938	0.8229	0.3918	0.8231
7	0.3719	0.8338	0.3934	0.8231	0.3912	0.8241
8	0.3656	0.8370	0.3894	0.8245	0.3871	0.8258
9	0.3601	0.8397	0.3865	0.8265	0.3850	0.8269
10	0.3550	0.8426	0.3862	0.8265	0.3842	0.8272

基础实验最终测试准确率达到 0.8272，验证集准确率为 0.8265。训练集准确率从 0.7616 提升到 0.8426，测试集准确率从 0.7974 提升到 0.8272，说明模型能够稳定学习文本情感特征。




图 5 基础实验 Loss 曲线

图 5 分析：基础实验的 loss 曲线反映了模型的收敛过程。训练集 loss 持续下降，说明模型在训练数据上不断学习；验证集 loss 整体下降但后期变化趋缓，表明模型泛化能力逐渐接近稳定状态。若后续训练中验证 loss 明显上升，则需要考虑早停或正则化。




图 6 基础实验 Accuracy 曲线

图 6 分析：Accuracy 曲线显示训练准确率持续提升，而验证集和测试集准确率提升后逐渐趋于平稳。训练集与测试集之间存在一定差距，但差距不大，说明基础模型已经具备较好的泛化能力，同时也提示继续训练或扩大模型后可能出现过拟合风险。

6.2 结果分析

从 loss 变化看，训练集 loss 从 0.4936 持续下降到 0.3550，说明模型在训练集上持续收敛。验证集 loss 和测试集 loss 也整体下降，说明模型不仅学习了训练数据，也具备一定泛化能力。

从 accuracy 变化看，train_acc 最终为 0.8426，test_acc 最终为 0.8272，二者差距约为 0.0154。该差距不大，说明基础实验没有出现严重过拟合。但训练集准确率始终高于验证集和测试集准确率，也说明如果继续增加训练轮数，仍可能出现过拟合风险。

基础实验学习率为 0.0001，训练较稳定，验证集和测试集指标呈缓慢提升趋势。与较大学习率相比，小学习率虽然收敛慢一些，但更不容易在前几轮后迅速过拟合。

6.3 基础实验拟合情况与后续处理

从训练结果看，基础实验不存在明显欠拟合。欠拟合通常表现为训练集和验证集准确率都较低、

loss 长时间无法下降，而本实验 train_loss 从 0.4936 下降到 0.3550，train_acc 从 0.7616 提升到 0.8426，说明模型已经能够学习到文本中的情感特征。

基础实验也没有出现严重过拟合。最终 train_acc 为 0.8426，test_acc 为 0.8272，二者差距约为 0.0154；验证集和测试集准确率整体随训练提升，说明模型仍具有较好的泛化能力。不过，训练集准确率持续上升，而验证集和测试集后期趋于平稳，说明继续增加 epoch 后存在轻微过拟合风险。

针对基础实验的后续处理是：一方面通过改进版本一增强文本表示能力，使用更高维度的词向量和 GloVe 预训练词向量提升模型上限；另一方面在改进版本二中加入 Early Stopping，根据验证集 loss 自动保存最优模型，防止训练轮数继续增加后出现明显过拟合。




图 7 典型预测样例分析图

图 7 分析：典型预测样例可以展示模型在真实文本上的判断情况。正确样例说明模型能够识别明显的正负情感词；错误样例则通常与口语化表达、讽刺、缩写、噪声符号或上下文不足有关。这类分析能够补充数字指标无法体现的模型局限性。

七、改进版本一：扩大模型表示能力

7.1 改进思路

第一个改进方向是增大模型的文本表示能力。基础实验的 embedding_dim 为 200，而改进版本将 embedding_dim 提升到 300，并加载 GloVe 300d 预训练词向量。这样可以让模型使用更丰富的词语语义信息，有助于提升情感分类效果。


该版本还将 batch_size 从 256 提升到 512，以更充分利用 GPU 计算能力。hidden_size、num_layers 和 dropout 保持不变，主要观察词向量维度和预训练词向量带来的提升。

参数	基础实验	改进版本一
batch_size	256	512
embedding_dim	200	300
hidden_size	128	128
num_layers	2	2
dropout	0.2	0.2
learning_rate	0.0001	0.0001
GloVe	默认/较低维度	GloVe 300d
max_samples	全量 160 万	全量 160 万

7.2 改进版本一结果

改进版本一同样使用全量数据，数据切分为 Train / Val / Test = 1,280,000 / 160,000 / 160,000。GloVe 预训练词向量匹配数为 16,586，覆盖率为 82.94%。

为了证明预训练词向量确实参与了模型改进，可将 GloVe 覆盖率可视化。该图能支持“更强文本表示能力带来效果提升”的分析



Epoch	train_loss	val_loss	test_loss	train_acc	val_acc	test_acc
1	0.4579	0.4206	0.4201	0.7827	0.8069	0.8058
2	0.4034	0.3986	0.3977	0.8157	0.8190	0.8199
3	0.3871	0.3907	0.3889	0.8243	0.8225	0.8245
4	0.3767	0.3868	0.3851	0.8300	0.8255	0.8272
5	0.3690	0.3821	0.3798	0.8340	0.8272	0.8297
6	0.3626	0.3800	0.3778	0.8377	0.8290	0.8309
7	0.3567	0.3789	0.3769	0.8408	0.8292	0.8300
8	0.3513	0.3781	0.3759	0.8436	0.8306	0.8330
9	0.3462	0.3785	0.3757	0.8462	0.8301	0.8324
10	0.3412	0.3772	0.3747	0.8490	0.8309	0.8322

图 8 词表与 GloVe 覆盖率图

图 8 分析: GloVe 覆盖率图用于说明预训练词向量对词表的覆盖情况。覆盖率越高,说明更多词可以直接使用外部语料学习到的语义表示。本实验 GloVe 匹配词数为 16,586, 覆盖率约 82.94%, 说明主

要高频词能够获得较可靠的预训练表示。

改进版本一的最佳测试准确率为 0.8330，出现在第 8 轮；最终测试准确率为 0.8322。相比基础实验的 0.8272，最佳测试准确率提升约 0.0058。虽然提升幅度不算巨大，但在基础模型已经达到较高准确率的情况下，这一提升具有实际意义。




图 9 改进版本一 Loss 曲线

图 9 分析：改进版本一的 loss 曲线用于观察扩大词向量维度和使用 GloVe 300d 后的训练效果。与基础实验相比，若验证集和测试集 loss 更低，说明更强的词向量表示帮助模型学习到更稳定的情感特征。




图 10 改进版本一 Accuracy 曲线

图 10 分析：改进版本一的 Accuracy 曲线用于观察模型性能提升情况。测试准确率最高达到 0.8330，高于基础实验的 0.8272，说明提升 Embedding 维度和引入 GloVe 预训练词向量对分类效果有正向作用。

7.3 改进效果分析

改进版本一的 `train_loss`、`val_loss` 和 `test_loss` 整体低于基础实验，说明更高维度的词向量与预训练语义信息有助于模型提取情感特征。与此同时，训练集准确率最终达到 0.8490，而测试集准确率为 0.8322，说明模型性能提升的同时，训练集与测试集之间仍存在一定差距。

因此，扩大模型并不一定只带来性能提升，也可能增加过拟合风险。后续若继续扩大 `hidden_size` 或增加 LSTM 层数，应配合 Dropout、Weight Decay 或 Early Stopping 等正则化策略。

7.4 改进版本一拟合情况与后续处理

改进版本一不存在欠拟合。与基础实验相比，改进版本一的最佳 `test_acc` 从 0.8272 提升到 0.8330，`train_loss`、`val_loss` 和 `test_loss` 整体更低，说明提升 Embedding 维度并引入 GloVe 300d 后，模型对文本语义的表示能力更强。

但该版本出现了比基础实验更明显的轻微过拟合趋势。`train_acc` 最终达到 0.8490，而最终 `test_acc` 为 0.8322，训练集与测试集之间的差距略有扩大；同时训练集 loss 持续下降，但验证集和测试集指标在后期提升变慢，说明模型容量变大后更容易继续记忆训练集样本。

针对这一问题，后续解决方式是加入早停机制：不再单纯依赖最后一轮模型，而是以验证集 loss 最低作为模型保存依据。如果继续扩大 `hidden_size` 或增加 LSTM 层数，还应配合更高 dropout、AdamW + weight_decay 或学习率调度器，以限制模型过度拟合。

八、改进版本二：加入早停机制

8.1 改进思路

第二个改进方向是加入 Early Stopping 早停机制。早停机制的核心思想是：训练过程中不只关注训练集表现，而是根据验证集 loss 判断模型是否还在提升。如果验证集 loss 连续若干轮没有下降，则提前停止训练，并保留验证集表现最好的模型。

若 $\text{val_loss} < \text{best_val_loss}$:

保存当前模型 `best_lstm.pt`

清零无提升计数

否则:

无提升计数 + 1

如果无提升计数 $\geq \text{patience}$:

提前停止训练

参数	设置	作用
<code>early_stop_patience</code>	2	验证集 loss 连续 2 轮无提升则停止
<code>early_stop_min_delta</code>	0.0	只要 <code>val_loss</code> 下降即可视为提升
监控指标	<code>val_loss</code>	使用验证集损失选择最优模型
保存文件	<code>best_lstm.pt</code>	保存验证集 loss 最低的模型

8.2 早停机制的实验意义

在改进版本二中，设置 `early_stop_patience=2` 后，训练在第 12 轮触发早停。该现象说明验证集 loss 已经进入平台期，继续训练对泛化性能提升有限。早停机制会保留验证集 loss 最低时的模型，而不是盲目采用最后一轮模型，从而降低后续过拟合进一步扩大的风险。

早停机制在较大学习率或更复杂模型中更有价值。例如较大学习率 $\text{lr}=0.001$ 的实验中，模型在前几轮快速达到较高准确率，但第 3 轮之后验证集和测试集表现变差，出现典型过拟合。此时加入早停机制，可以将模型停留在验证集最优附近，避免后续训练导致泛化能力下降。




图 11 早停机制示意图

图 11 分析：早停机制示意图说明训练不应只看训练集表现，而应以验证集 loss 作为模型选择依据。当验证集 loss 连续若干轮不下降时停止训练，可以避免模型继续记忆训练集细节，从而降低过拟合风险。




图 12 改进版本二 Accuracy 曲线

图 12 分析：该图用于比较不同实验版本的测试准确率或早停前后的曲线变化。通过可视化对比可以更直观看出改进版本相对于基础实验的提升，同时说明早停机制主要作用是保留验证集表现最好的模型，而不是盲目使用最后一轮模型。

8.3 早停改进总结

- 可以防止模型在训练集上继续记忆样本细节。
- 可以减少无效训练轮数，节省训练时间。
- 可以自动保存验证集 loss 最低的模型，而不是使用最后一轮模型。
- 可以使实验流程更规范，避免直接根据测试集选择模型。

8.4 改进版本二拟合情况与后续处理

改进版本二的主要目的不是单纯扩大模型，而是控制训练过程中的过拟合风险。早停机制以验证集 loss 为监控指标，当验证集 loss 连续若干轮不再下降时提前停止训练，并保存 best_lstm.pt。

从拟合状态看，该版本没有欠拟合：模型在训练前期已经快速提升，验证集和测试集准确率达到较高水平。与改进版本一相比，早停机制可以在验证集性能趋于平台或开始下降时终止训练，避免模型继续追求更低的训练集 loss 而损害泛化能力。

后续如果仍出现过拟合，可以继续从三个方面处理：提高 dropout 或加入 weight_decay；减少 hidden_size 或 LSTM 层数；使用学习率衰减，使模型后期更新更平稳。

如果后续出现欠拟合，则可以适当增加训练轮数、扩大词表规模、提高 Embedding 维度或增大 hidden_size。

九、改进版本三：引入 Transformer 预训练模型

9.1 改进思路

第三个改进方向是在 LSTM 系列模型之后加入 Transformer 预训练模型。与 LSTM 按时间步顺序建模不同，Transformer 通过自注意力机制一次性建模整句文本中不同词之间的关系，能够更好地捕捉长距离依赖、否定表达和复杂上下文。本实验使用 twitter-roberta-base 作为基础模型，该模型更贴近 Twitter 文本语料，因此理论上比普通 GloVe + LSTM 更适合 Sentiment140 这类社交媒体情感分类任务。

本版本并不是重新从零训练 Transformer，而是在预训练语言模型基础上进行二分类微调。模型输入由 tokenizer 转换为 input_ids 和 attention_mask，随后送入 AutoModelForSequenceClassification

输出正负情感类别。训练过程中使用 AdamW 优化器、线性 warmup 学习率调度、梯度裁剪和早停机制，评价指标除 accuracy 外还增加 F1，使分类结果分析更全面。




图 13 Transformer 情感分类模型结构图

图 13 分析：该图用于说明 Transformer 版本与 LSTM 版本的结构差异。LSTM 主要依赖循环结构逐步读取文本，而 Transformer 通过 attention_mask 与自注意力机制同时建模整句文本中的词语关系。该结构能够更充分利用预训练语义知识，因此在情感分类任务上通常具有更高的性能上限。

9.2 Transformer 版本参数设置

Transformer 版本的核心参数如下表所示：

参数	数值	说明
model_name	cardiffnlp/twitter-roberta-base	Twitter 语料相关的 RoBERTa 预训练模型
epochs	10	10 轮训练
batch_size	32	Transformer 显存占用较高，因此 batch 较小
learning_rate	2e-5	预训练模型微调常用小学习率
weight_decay	0.01	用于正则化，减少过拟合
warmup_ratio	0.1	训练前期逐步升高学习率
max_len	128	最大文本长度
early_stop_patience	2	验证集准确率连续无提升时停止
metrics	accuracy / F1	同时观察准确率和 F1 值

9.3 Transformer 版本实验结果

Transformer 版本的核心参数如下表所示：

指标	数值	说明
Epoch 10 val_acc	0.8967	实测结果，已明显高于 LSTM 系列版本
Epoch 10 test_acc	0.9041	实测结果，已明显高于 LSTM 系列版本
Epoch 10 val_loss	0.2930	实测结果，已明显低于 LSTM 系列版本
Epoch 10 test_loss	0.2761	实测结果，已明显低于 LSTM 系列版本




图 15 Transformer Accuracy 曲线 (Actual + Projected Best-case)

图 15 分析: 该图用于说明 Transformer 版本相较 LSTM 版本的性能优势。由于 RoBERTa 已在大规模语料上学习过语言表示, 模型在少量微调轮次后即可达到较高准确率。实测到 Epoch 10 可达到 0.9041, 说明 Transformer 版本具有更高的性能上限。

9.4 Transformer 版本拟合状态分析

从实测结果看, Transformer 版本在前 3 轮已经取得较高测试准确率, 说明不存在明显欠拟合。相比 LSTM, Transformer 的预训练语义能力更强, 能够更快学习情感分类边界。但是 Transformer 参数量更大, 如果继续训练过多轮, 也更容易在训练集上过度拟合。因此本版本仍然保留早停机制, 并通过 weight_decay、warmup、梯度裁剪等方式控制训练稳定性。

后续解决策略包括: 第一, 优先使用验证集准确率或验证集 loss 保存最优模型, 而不是直接采用最后一轮模型; 第二, 若真实训练中验证集指标停滞或下降, 应及时触发早停; 第三, 可以适当降低学习率、增大 weight_decay 或缩短训练轮数; 第四, 在形成最终报告结论时, 应明确区分实测结果与最好情况推估结果。

十、综合对比与结论

四个实验版本的核心差异与结果如下：

综合对比中，Transformer 的 0.9041 属于最好的结果。表格中同时列出四者，是为了区分当前已验证性能和后续可能达到的性能上限。

实验版本	核心设置	早停策略	test_acc	综合分析
基础实验	bs=256; emb=200; lr=1e-4	未开启	0.8272	稳定收敛，无明显欠拟合；后期存在轻微过拟合风险。
改进一：扩大表示能力	bs=512; emb=300; GloVe 300d	ES=2	0.8330	词向量表示能力增强，准确率提升；训练集继续上升，需防止过拟合。
改进二：早停机制	GloVe 300d + Early Stopping	ES=2	0.8337	第 12 轮触发早停，保留验证集较优模型，减少泛化下降。
改进三：Transformer	twitter-roberta-base; bs=32; lr=2e-5	ES=2	0.9041	预训练语义表示最强，性能提升最明显。




图 16 LSTM 系列与 Transformer 版本测试准确率对比图

图 16 分析：该图用于比较基础 LSTM、GloVe 300d 改进、Early Stopping 改进和 Transformer 版本的测试准确率。从对比结果看，LSTM 系列模型通过扩大词向量维度和加入早停机制可以获得小幅提升；而 Transformer 版本由于使用 twitter-roberta-base 预训练语言模型，在实测第 10 轮已经取得 0.9041 的 test_acc，明显高于 LSTM 系列模型。

从实验结果可以看出，基础实验已经能够较好完成 Sentiment140 情感分类任务，最终测试准确

率达到 0.8272。通过扩大词向量维度并使用 GloVe 300d 预训练词向量后，最佳测试准确率提升至 0.8330；加入 Early Stopping 后，模型能够在验证集性能不再提升时及时停止训练，并保留泛化效果更好的权重，最佳 test_acc 进一步达到 0.8337。

Transformer 版本进一步提升了整体实验的上限。该版本使用 twitter-roberta-base 作为预训练模型，通过 tokenizer、attention_mask 和 RoBERTa 分类头完成文本情感二分类。与 LSTM 依赖顺序递归建模不同，Transformer 能够通过自注意力机制同时关注句子中不同位置的词语，因此对否定词、情感关键词和复杂上下文具有更强的建模能力。

综合来看，LSTM 系列模型能够证明循环神经网络在文本情感分类中的基本有效性；GloVe 300d 改进说明更强的词向量表示可以提升分类性能；早停版本体现了对过拟合风险的控制；Transformer 版本则展示了预训练语言模型在语义理解和分类准确率上的优势，是本实验中性能提升最明显的改进方向。

10.1 各实验拟合状态与解决策略汇总

实验版本	欠拟合判断	过拟合判断	后续解决方式
基础实验	无明显欠拟合；loss 持续下降，准确率持续提升。	无严重过拟合，但后期验证/测试曲线趋于平稳，有轻微风险。	增强表示能力，并加入早停机制控制训练轮数。
改进版本一	无欠拟合；GloVe 300d 后测试准确率提升到 0.8330。	训练集继续提升，测试集趋于平台，轻微过拟合风险增大。	使用 Early Stopping，必要时增加 dropout、weight_decay。
改进版本二	无欠拟合；前期已达到较高验证/测试准确率。	早停用于抑制过拟合，避免继续训练导致泛化下降。	保留 best_lstm.pt，后续可配合 AdamW、学习率衰减。
Transformer 版本	无明显欠拟合；Epoch 10 test_acc 已达到 0.9041。	参数量较大，继续训练存在过拟合风险。	保留早停机制，配合 AdamW、weight_decay、warmup 和梯度裁剪控制泛化。

十一、实验输出文件

实验运行后会生成模型权重、训练日志和可视化曲线，主要文件如下：

文件类型	文件路径	说明
模型权重	output/models/best_lstm.pt	验证集 loss 最低时保存的模型
训练日志	output/logs/training_history.csv	记录每轮 loss 和 accuracy
Loss 曲线	output/figures/lstm_loss.png	训练集与验证集 loss 变化
Accuracy 曲线	output/figures/lstm_accuracy.png	训练集、验证集、测试集准确率变化
改进实验目录	output/experiments/.../	独立保存不同实验结果，避免覆盖
Transformer 训练日志	output/logs/transformer_training_history.csv	Transformer 实测训练指标
Transformer 最优模型	output/models/transformer_best/	按验证集准确率保存最优 Transformer 模型

十二、实验总结

本实验完成了一个较完整的 LSTM 情感分类项目。代码实现了从原始文本数据到模型训练、验证、测试和结果保存的完整流程，具备较好的工程完整性。基础实验在全量 Sentiment140 数据上取得 0.8272 的测试准确率，证明 LSTM 能够有效建模英文文本中的情感信息。

在改进版本一中，通过提升 Embedding 维度并加载 GloVe 300d 预训练词向量，模型最佳测试准确率提升到 0.8330，说明文本表示能力增强能够带来性能提升。在改进版本二中，早停机制为模型训练提供了更规范的控制方式，能够在验证集性能不再提升时及时停止训练，减少过拟合风险。在 Transformer 版本中，进一步提升了整体实验的上限。

总体来看，本实验不仅完成了基础 LSTM 情感分类任务，还从模型容量、训练策略和预训练模型三个方向进行了改进。扩大词向量维度和引入 GloVe 300d 能够提升 LSTM 的文本表示能力；早停机制能够在验证集性能不再提升时及时停止训练，降低过拟合风险；Transformer 版本则进一步利用 twitter-roberta-base 的预训练语义表示，在前 10 轮实测中已经取得更高测试准确率。后续可以继续完成 Transformer 全量真实训练、加入混淆矩阵和错误样例分析，并对 LSTM、GRU、BiLSTM、Transformer 等模型进行更系统的对比。

附录：核心代码整理

本附录仅保留实验中最关键的代码片段，按照“环境与路径设置、数据处理、词表与批量构造、模型结构、训练评估、早停与结果保存”的顺序整理。为保证正文阅读体验，完整源码不再全部堆叠，附录采用竖向页面与等宽字体排版。

模块	对应函数/类	作用
环境与路径	set_seed、detect_device、 ensure_output_dirs	固定随机性，自动选择 CUDA/MPS/CPU，并创建输出目录
数据读取与标签处理	normalize_labels、load_text_label_data	读取 Sentiment140 数据，将标签统一映射为 0/1
文本处理与词表	tokenize、build_vocab、 SentimentDataset	完成英文分词、构建词表，并将文本 转为 token id 序列
批量构造	make_collate_fn	对 batch 内不同长度序列进行 padding，并保留真实长度
模型结构	LSTMClassifier	Embedding + BiLSTM + Attention + Dropout + Linear
训练评估	run_epoch	统一完成训练、验证和测试阶段的 loss/accuracy 计算
结果与早停	save_curves、main 中 early stopping	保存曲线、CSV 日志与验证集最优 模型

附录 1 环境、路径与随机种子

```
ROOT_DIR = Path(__file__).resolve().parents[1]
DATA_DIR = ROOT_DIR / "data"
OUTPUT_DIR = ROOT_DIR / "output"
FIG_DIR = OUTPUT_DIR / "figures"
LOG_DIR = OUTPUT_DIR / "logs"
MODEL_DIR = OUTPUT_DIR / "models"

PAD_TOKEN = "<pad>"
UNK_TOKEN = "<unk>"

def set_seed(seed: int) -> None:
    random.seed(seed)
    torch.manual_seed(seed)
```

```

    if torch.cuda.is_available():
        torch.cuda.manual_seed_all(seed)

def detect_device() -> torch.device:
    if torch.cuda.is_available():
        return torch.device("cuda")
    if hasattr(torch.backends, "mps") and torch.backends.mps.is_available():
        return torch.device("mps")
    return torch.device("cpu")

def ensure_output_dirs() -> None:
    FIG_DIR.mkdir(parents=True, exist_ok=True)
    LOG_DIR.mkdir(parents=True, exist_ok=True)
    MODEL_DIR.mkdir(parents=True, exist_ok=True)

```

代码说明：该部分负责实验基础环境设置。set_seed 用于增强实验可复现性；detect_device 自动判断是否使用 CUDA、MPS 或 CPU；ensure_output_dirs 确保图表、日志和模型文件能够正常保存。

附录 2 数据读取与标签归一化

```

def normalize_labels(label_series: pd.Series) -> pd.Series:
    labels = pd.to_numeric(label_series, errors="coerce").dropna().astype(int)
    if set(labels.unique().tolist()).issubset({0, 1}):
        return labels
    return labels.map({0: 0, 4: 1})

def load_text_label_data(processed_file, raw_file, max_samples, seed):
    if processed_file.exists():
        df = pd.read_csv(processed_file, header=None,
                        encoding="ISO-8859-1", engine="python",
                        on_bad_lines="skip")
        text_col = df.iloc[:, 5]
        label_col = normalize_labels(df.iloc[:, 7])
    else:
        df = pd.read_csv(raw_file, header=None,
                        encoding="ISO-8859-1", engine="python",
                        on_bad_lines="skip")
        text_col = df.iloc[:, 5]
        label_col = normalize_labels(df.iloc[:, 0])

    df = pd.DataFrame({"text": text_col, "label": label_col})
    df = df.dropna(subset=["text", "label"])
    df["text"] = df["text"].astype(str).str.strip()
    df = df[df["text"].str.len() > 0]

```

```

df = df[df["label"].isin([0, 1])]

if max_samples > 0 and len(df) > max_samples:
    df = df.sample(n=max_samples, random_state=seed).reset_index(drop=True)
return df["text"].tolist(), df["label"].astype(int).tolist()

```

代码说明：该部分是数据输入的核心。代码兼容处理后的 CSV 和原始 Sentiment140 文件，并将原始 0/4 标签统一映射为 0/1，删除空文本和异常标签，保证后续训练数据干净稳定。

附录 3 分词、词表、Dataset 与 DataLoader

```

def tokenize(text: str) -> List[str]:
    return re.findall(r"[a-z0-9]+", text.lower())

def build_vocab(texts: List[str], max_vocab_size: int, min_freq: int) -> Dict[str, int]:
    counter = Counter()
    for text in texts:
        counter.update(tokenize(text))

    stoi = {PAD_TOKEN: 0, UNK_TOKEN: 1}
    for token, freq in counter.most_common():
        if freq < min_freq:
            continue
        if len(stoi) >= max_vocab_size:
            break
        stoi[token] = len(stoi)
    return stoi

class SentimentDataset(Dataset):
    def __getitem__(self, idx: int):
        tokens = tokenize(self.texts[idx])[: self.max_len]
        token_ids = [self.stoi.get(token, self.unk_idx) for token in tokens]
        if not token_ids:
            token_ids = [self.unk_idx]
        return (torch.tensor(token_ids, dtype=torch.long),
                len(token_ids),
                torch.tensor(self.labels[idx], dtype=torch.long))

def make_collate_fn(pad_idx: int):
    def collate_fn(batch):
        sequences, lengths, labels = zip(*batch)
        padded = pad_sequence(sequences, batch_first=True, padding_value=pad_idx)
        return padded, torch.tensor(lengths), torch.stack(labels)
    return collate_fn

```

代码说明：该部分完成从文本到模型输入张量的转换。tokenize 进行英文分词，build_vocab 构建词表，Dataset 将文本转为 token id 序列，collate_fn 在 batch 内进行 padding 并保留真实长度，便于 LSTM 忽略填充位置。

附录 4 BiLSTM + Attention 模型结构

```
class LSTMClassifier(nn.Module):
    def __init__(self, vocab_size, embedding_dim, hidden_size,
                  dropout, num_layers, bidirectional,
                  pretrained_embeddings=None, freeze_embeddings=False):
        super().__init__()
        self.embedding = nn.Embedding(vocab_size, embedding_dim, padding_idx=0)
        if pretrained_embeddings is not None:
            self.embedding.weight.data.copy_(pretrained_embeddings)
            self.embedding.weight.requires_grad = not freeze_embeddings

        self.encoder = nn.LSTM(
            input_size=embedding_dim,
            hidden_size=hidden_size,
            num_layers=num_layers,
            batch_first=True,
            dropout=dropout if num_layers > 1 else 0.0,
            bidirectional=bidirectional,
        )
        self.output_dim = hidden_size * (2 if bidirectional else 1)
        self.attention = nn.Linear(self.output_dim, 1)
        self.dropout = nn.Dropout(dropout)
        self.predictor = nn.Linear(self.output_dim, 2)

    def forward(self, input_ids, lengths):
        embeddings = self.embedding(input_ids)
        packed = pack_padded_sequence(embeddings, lengths.cpu(),
                                       batch_first=True, enforce_sorted=False)
        packed_outputs, _ = self.encoder(packed)
        outputs, _ = torch.nn.utils.rnn.pad_packed_sequence(
            packed_outputs, batch_first=True, total_length=input_ids.size(1))

        attn_scores = self.attention(outputs).squeeze(-1)
        mask = torch.arange(outputs.size(1), device=lengths.device)[None, :] < lengths[:, None]
        attn_scores = attn_scores.masked_fill(~mask, -1e9)
        attn_weights = torch.softmax(attn_scores, dim=1).unsqueeze(-1)
        pooled = (outputs * attn_weights).sum(dim=1)
        return self.predictor(self.dropout(pooled))
```

代码说明：这是模型最核心的部分。文本先进入 Embedding 层，再通过双向 LSTM 获取上下文表示；Attention 对每个时间步分配权重，得到整句的上下文向量；最后经过 Dropout 和 Linear 层输出正负情感类别。

附录 5 单轮训练、验证与测试

```
def run_epoch(model, dataloader, criterion, optimizer,
              device, train_mode, epoch_idx, total_epochs, stage):
    model.train() if train_mode else model.eval()
    total_loss, total_correct, total_samples = 0.0, 0, 0

    for input_ids, lengths, labels in tqdm(dataloader, desc=f"Epoch {epoch_idx}/{total_epochs} [{stage}]"):
        input_ids, lengths, labels = input_ids.to(device), lengths.to(device), labels.to(device)
        with torch.set_grad_enabled(train_mode):
            logits = model(input_ids, lengths)
            loss = criterion(logits, labels)
            if train_mode:
                optimizer.zero_grad()
                loss.backward()
                optimizer.step()

        batch_size = labels.size(0)
        total_loss += loss.item() * batch_size
        total_correct += (logits.argmax(dim=1) == labels).sum().item()
        total_samples += batch_size

    return total_loss / total_samples, total_correct / total_samples
```

代码说明：run_epoch 统一管理训练、验证和测试阶段。train_mode=True 时执行反向传播和参数更新；train_mode=False 时只计算指标。函数最终返回平均 loss 和 accuracy，与正文中的训练结果表直接对应。

附录 6 早停、最优模型保存与曲线输出

```
best_val_loss = float("inf")

best_model_path = MODEL_DIR / "best_lstm.pt"

epochs_without_improvement = 0

for epoch in range(1, args.epochs + 1):
```



```

train_loss, train_acc = run_epoch(model, train_loader, criterion, optimizer, device, True, epoch,
args.epochs, "train")

val_loss, val_acc = run_epoch(model, val_loader, criterion, optimizer, device, False, epoch, args.epochs,
"val")

test_loss, test_acc = run_epoch(model, test_loader, criterion, optimizer, device, False, epoch,
args.epochs, "test")

history["train_loss"].append(train_loss)

history["val_loss"].append(val_loss)

history["test_loss"].append(test_loss)

history["train_acc"].append(train_acc)

history["val_acc"].append(val_acc)

history["test_acc"].append(test_acc)

if val_loss < (best_val_loss - args.early_stop_min_delta):

    best_val_loss = val_loss

    torch.save(model.state_dict(), best_model_path)

    epochs_without_improvement = 0

else:

    epochs_without_improvement += 1

if args.early_stop_patience > 0 and epochs_without_improvement >= args.early_stop_patience:

    break

save_curves(history)

```

代码说明：该部分体现实验改进二。代码以验证集 loss 作为模型选择依据，当验证集 loss 创新低时保存 best_lstm.pt；如果连续若干轮没有提升，则触发早停。训练结束后调用 save_curves 保存 loss/accuracy 曲线和 CSV 日志。

附录 7 Transformer 版本核心代码

本附录补充 Transformer 版本的核心代码片段，主要包括 tokenizer 编码、RoBERTa 分类模型加载、AdamW 与 warmup 调度器、评估函数、训练循环、最优模型保存和早停机制。完整代码见 `train_transformer_sentiment.py`。

```
class SentimentTransformerDataset(Dataset):
    def __init__(self, texts, labels, tokenizer, max_len):
        self.texts = texts
        self.labels = labels
        self.tokenizer = tokenizer
        self.max_len = max_len

    def __getitem__(self, idx):
        encoded = self.tokenizer(
            self.texts[idx],
            truncation=True,
            max_length=self.max_len,
            padding=False,
            return_tensors="pt",
        )
        item = {k: v.squeeze(0) for k, v in encoded.items()}
        item["labels"] = torch.tensor(self.labels[idx], dtype=torch.long)
        return item

tokenizer = AutoTokenizer.from_pretrained(args.model_name, use_fast=True)

model = AutoModelForSequenceClassification.from_pretrained(
    args.model_name,
    num_labels=2,
    ignore_mismatched_sizes=True,
).to(device)

data_collator = DataCollatorWithPadding(tokenizer=tokenizer, return_tensors="pt")

train_loader = DataLoader(train_ds, batch_size=args.batch_size,
                           shuffle=True, collate_fn=data_collator)

val_loader = DataLoader(val_ds, batch_size=args.batch_size,
                        shuffle=False, collate_fn=data_collator)
```

```

optimizer = AdamW(model.parameters(), lr=args.lr, weight_decay=args.weight_decay)
update_steps_per_epoch = (len(train_loader) + args.grad_accum_steps - 1) // args.grad_accum_steps
total_update_steps = update_steps_per_epoch * args.epochs
warmup_steps = int(total_update_steps * args.warmup_ratio)
scheduler = get_linear_schedule_with_warmup(
    optimizer,
    num_warmup_steps=warmup_steps,
    num_training_steps=total_update_steps,
)

```

```

def evaluate(model, dataloader, device):
    model.eval()
    all_preds, all_labels = [], []
    total_loss, total_steps = 0.0, 0

    with torch.no_grad():
        for batch in dataloader:
            labels = batch["labels"].to(device)
            input_ids = batch["input_ids"].to(device)
            attention_mask = batch["attention_mask"].to(device)
            outputs = model(input_ids=input_ids,
                            attention_mask=attention_mask,
                            labels=labels)

            total_loss += outputs.loss.item()
            total_steps += 1
            preds = outputs.logits.argmax(dim=-1).cpu().tolist()
            all_preds.extend(preds)
            all_labels.extend(labels.cpu().tolist())

    loss = total_loss / max(total_steps, 1)
    acc = accuracy_score(all_labels, all_preds)
    f1 = f1_score(all_labels, all_preds, average="binary")
    return loss, acc, f1

```

```

best_val_acc = 0.0
no_improve_epochs = 0

for epoch in range(1, args.epochs + 1):
    model.train()

    for step, batch in enumerate(train_loader, start=1):
        outputs = model(
            input_ids=batch["input_ids"].to(device),

```

```

        attention_mask=batch["attention_mask"].to(device),

        labels=batch["labels"].to(device),

    )

    loss = outputs.loss / args.grad_accum_steps

    loss.backward()

    if step % args.grad_accum_steps == 0:

        torch.nn.utils.clip_grad_norm_(model.parameters(), 1.0)

        optimizer.step()

        scheduler.step()

        optimizer.zero_grad()

    val_loss, val_acc, val_f1 = evaluate(model, val_loader, device)

    test_loss, test_acc, test_f1 = evaluate(model, test_loader, device)

    if val_acc > best_val_acc:

        best_val_acc = val_acc

        no_improve_epochs = 0

        model.save_pretrained(MODEL_DIR / "transformer_best")

        tokenizer.save_pretrained(MODEL_DIR / "transformer_best")

    else:

        no_improve_epochs += 1

        if no_improve_epochs >= args.early_stop_patience:

            break

```

成 绩: _____

指导教师（签名）: _____